# Estimação, Deteção e Análise II

#### 04 - Técnicas de Melhoria

Bagging Random Forests Boosting

# Bagging para classificação

## 1. Criar um dataset para classificação de forma aleatória

### 2. Definir o modelo

```
from sklearn.ensemble import BaggingClassifier
model = BaggingClassifier()
```

## 3. Avaliar o modelo e mostrar a performance

#### Resultado:

Accuracy: 0.866 (0.043)

Nota: Dada a aleatoriedade, o resultado pode variar

### 4. Fazer fit do modelo e aplicá-lo a uma nova instância

## Resultado:

Predicted Class: 1



IMP.GE.194.0 1/5

# Comparação de métodos Bagging em classificação

1. Importar o dataset iris e dividi-lo em variáveis independentes e dependente, treino e teste

```
from sklearn import datasets
iris = datasets.load_iris()

from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(iris.data, iris.target)
```

## 2. Definir os modelos a utilizar

# 3. Definir a grid (base model, número de base models), correr o bagging e guardar o resultado


## 4. Converter os resultados num dataframe e atribuir nomes às colunas

```
from pandas import DataFrame
results = DataFrame(results)
results.columns = ['Base estimator','Nr estimators','Accuracy']
```

# 5. Visualizar graficamente os resultados

```
from matplotlib import pyplot
import seaborn
seaborn.set(style='ticks')
fg = seaborn.FacetGrid(data=results, hue='Base estimator', aspect=1.61)
fg.map(pyplot.plot, 'Nr estimators', 'Accuracy', marker='o').add_legend()
fg.savefig('bagging_comp.png')
```

# Resultado:



UPI UNIVERSIDADE PORTUCALENSE

IMP.GE.194.0 2/5

# Bagging para regressão

# 1. Criar um dataset para regressão de forma aleatória

```
from sklearn.datasets import make_regression
X, y = make_regression(n_samples=1000, n_features=20, n_informative=15, noise=0.1,
    random state=5)
```

#### 2. Definir o modelo

```
from sklearn.ensemble import BaggingRegressor
model = BaggingRegressor()
```

### 3. Avaliar o modelo e mostrar a performance

#### Resultado:

MAE: -101.255 (9.184)

Nota: Dada a aleatoriedade, o resultado pode variar

# 4. Fazer fit do modelo e aplicá-lo a uma nova instância

#### Resultado:

Prediction: -187

UPI UNIVERSIDADE PORTUCALENSE

IMP.GE.194.0 3/5

# **Random Forests**

1. Importar o dataset iris e dividi-lo em variáveis independentes e dependente, treino e teste

```
from sklearn import datasets
iris = datasets.load_iris()

from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(iris.data, iris.target)
```

2. Definir a *grid* (número de *base models* e número de *features* a escolher em cada *split*), correr o *random forests* e guardar o resultado

```
results = []
from sklearn.ensemble import RandomForestClassifier
from sklearn.model_selection import RepeatedStratifiedKFold
from sklearn.model_selection import cross_val_score
from numpy import mean
for n_estimator in [1, 50, 100, 250, 500, 750, 1000, 2500, 5000]:
    for features in ['auto', 'sqrt', 'log2']:
        print(n_estimator, features)
        model = RandomForestClassifier(n_estimators=100, max_features="auto")
        cv = RepeatedStratifiedKFold(n_splits=10, n_repeats=3, random_state=1)
        n_scores = cross_val_score(model, X_train, y_train, scoring='accuracy', cv=cv,
n_jobs=-1, error_score='raise')
    res = [n_estimator, features, mean(n_scores)]
    results.append(res)
```


3. Converter os resultados num dataframe e atribuir nomes às colunas

```
from pandas import DataFrame
results = DataFrame(results)
results.columns =['Nr estimators', 'Features', 'Accuracy']
```

4. Visualizar graficamente os resultados

```
from matplotlib import pyplot
import seaborn
seaborn.set(style='ticks')
fg = seaborn.FacetGrid(data=results, hue='Features', aspect=1.61)
fg.set(ylim=(results['Accuracy'].min()-0.0025, results['Accuracy'].max()+0.0025))
fg.map(pyplot.plot, 'Nr estimators', 'Accuracy', marker='.').add_legend()
fg.savefig('randomForests.png')
```

# Resultado:



Nota: Dada a aleatoriedade, o resultado pode variar

UNIVERSIDADE PORTUCALENSE

IMP.GE.194.0 4/5

# Boosting (AdaBoost)

1. Importar o dataset iris e dividi-lo em variáveis independentes e dependente, treino e teste

```
from sklearn import datasets
iris = datasets.load_iris()

from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(iris.data, iris.target)
```

2. Definir a *grid* (número de iterações), correr o *AdaBoost* (*default base learner*: *decision trees*) e guardar o resultado

```
results = []
from sklearn.ensemble import AdaBoostClassifier
from sklearn.model_selection import RepeatedStratifiedKFold
from sklearn.model_selection import cross_val_score
from numpy import mean
for n_estimator in [1, 10, 20, 30, 40, 50, 60, 70, 80, 90, 100]:
    print(n_estimator)
    model = AdaBoostClassifier(n_estimators=n_estimator)
    cv = RepeatedStratifiedKFold(n_splits=10, n_repeats=3, random_state=1)
    n_scores = cross_val_score(model, X_train, y_train, scoring='accuracy', cv=cv,
n_jobs=-1, error_score='raise')
    res = [n_estimator, mean(n_scores)]
    results.append(res)
```


3. Converter os resultados num dataframe e atribuir nomes às colunas

```
from pandas import DataFrame
results = DataFrame(results)
results.columns =['Nr estimators', 'Accuracy']
```

4. Visualizar graficamente os resultados

```
from matplotlib import pyplot
import seaborn
seaborn.set(style='ticks')
fg = seaborn.FacetGrid(data=results, aspect=1.61)
fg.set(ylim=(results['Accuracy'].min()-0.0025, results['Accuracy'].max()+0.0025))
fg.map(pyplot.plot, 'Nr estimators', 'Accuracy', marker='.').add_legend()
fg.savefig('adaboost.png')
```

#### Resultado:



UNIVERSIDADE PORTUCALENSE

IMP.GE.194.0 5/5